

Curso de Especialização Inteligência Artificial



Eduardo L. L. Cabral



Inteligência artificial

- Inteligência Artificial (IA) é a área da ciência que se propõe a desenvolver sistemas que simulam a capacidade humana de raciocinar, perceber, tomar decisões e resolver problemas
- Inteligência artificial consiste na simulação da inteligência humana em máquinas que são programadas para pensar como seres humanos e imitar suas ações
- Uma máquina possui “inteligência” quando exhibe características associadas à mente humana, tal como aprendizado e solução de problemas
- A principal característica da inteligência artificial é sua capacidade de racionalizar e executar ações para atingir um objetivo específico

Inteligência artificial

- Início nos anos 1940 \Rightarrow teve grande impulso nos anos 2010 com o aumento da capacidade dos computadores
- Atualmente existem várias linhas de estudo da IA:
 - IA Forte x IA Fraca
 - IA clássica
 - Aprendizado de máquina (ML)
 - Redes neurais artificiais ou “deep-learning” (RNA-DL)
- Muitas aplicações atualmente:
 - jogos, aplicativos de segurança, robótica, reconhecimentos de escrita a mão, reconhecimento de voz, tradução de texto, programas de diagnósticos médicos e muito mais.
- As aplicações de inteligência artificial são infinitas \Rightarrow pode ser aplicada a qualquer tipo de indústria ou serviço

Inteligência artificial


- IA Fraca:
 - Relacionada com a construção de máquinas ou softwares de certa forma inteligentes, porém, não capazes de raciocinar por si próprios
 - IA Fraca não é capaz de raciocinar \Rightarrow basicamente simula a inteligência
 - Não é de fato inteligente e não possui autoconsciência
- IA Forte:
 - Relacionada à criação de máquinas que tenham autoconsciência e que possam pensar, e não somente simular raciocínios
 - Ainda está muito longe de ser alcançada, se é que será alcançada algum dia

Inteligência Artificial

- Duas abordagens de IA:
 - Baseada em conhecimento (IA clássica) \Rightarrow não funciona direito, atualmente foi praticamente abandonada
 - Baseada em dados (ML e RNA) \Rightarrow todas as aplicações atuais de sucesso são desse tipo


Inteligência artificial

- Engloba ML, RNA, DL e outras abordagens
- Relação entre IA, ML e RNA




Aprendizado de máquina (ML)

- **ML \Rightarrow novo paradigma da computação**
- Computação clássica




- ML \Rightarrow cálculos realizados em duas etapas



Aprendizado de máquina (ML)

- Exemplo \Rightarrow identificar atividade física de pessoas usando imagens
- Computação clássica:
 - Dados são as imagens, que consistem de uma matriz de números
 - Muitas variações para a mesma atividade
 - Como definir regras?
- ML:
 - Muito mais simples e mais eficiente \Rightarrow basta fornecer imagens e as atividades associadas
 - Sistema aprende regras sozinho



Inteligência artificial clássica

- Início nos anos 1940
- Baseada em regras e em busca num banco de dados
- Métodos da IA Clássica \Rightarrow Sistemas especialistas, Lógica fuzzy.
- Bom para algumas aplicações \Rightarrow jogo de xadrez
- Não funciona direito para outras áreas, tais como:
 - Problemas de classificação (imagens)
 - Reconhecimento de fala
 - Processamento de linguagem natural
 - “Chatbots”

Aprendizado de máquina (ML)

- Subárea da IA
- Início nos anos 1990
- Engloba RNA e outras abordagens
- Sistema de ML é treinado usando dados e não programado usando regras \Rightarrow aprendizado por dados
- Baseado em conceitos da estatística:
 - Utiliza muitos dados para treinamento (centenas, milhares, ou milhões)
 - Pouco baseado em teoria matemática \Rightarrow provas de funcionamento são experimentais

Aprendizado de máquina (ML)

- Teve grande avanço com o aumento da capacidade dos computadores
- Métodos de ML:
 - Regressão linear
 - Regressão logística
 - Máquina de vetores de suporte (SVM)
 - Métodos de agrupamento (K-means, Mapa de Kohonen etc)
 - Análise de componentes principais (PCA)
 - “Random Forest”
 - XGBoost
 - etc


Redes neurais (RN) e deep-learning (DL)

- Subárea de ML
- Início nos anos 1940, mas desenvolvimento parou por cerca de 15 anos por volta de 1970
- Redes neurais artificiais são inspiradas no sistema nervoso biológico (cérebro humano)
- Estrutura das redes neurais \Rightarrow grande número de elementos de processamento simples (neurônios) interconectados trabalhando em conjunto
- Como no caso de ML o treinamento (aprendizado) é realizado usando dados (via exemplos)


Redes neurais (RN) e deep-learning (DL)

- Redes neurais deep-learning \Rightarrow redes neurais com muitas camadas de neurônios
- Principais tipos de redes neurais artificiais DL:
 - Rede densa ou totalmente conectada (padrão)
 - Rede convolucional (visão computacional)
 - Rede recorrente (séries temporais, processamento de linguagem natural)


Tipo de de redes neurais



Rede densa



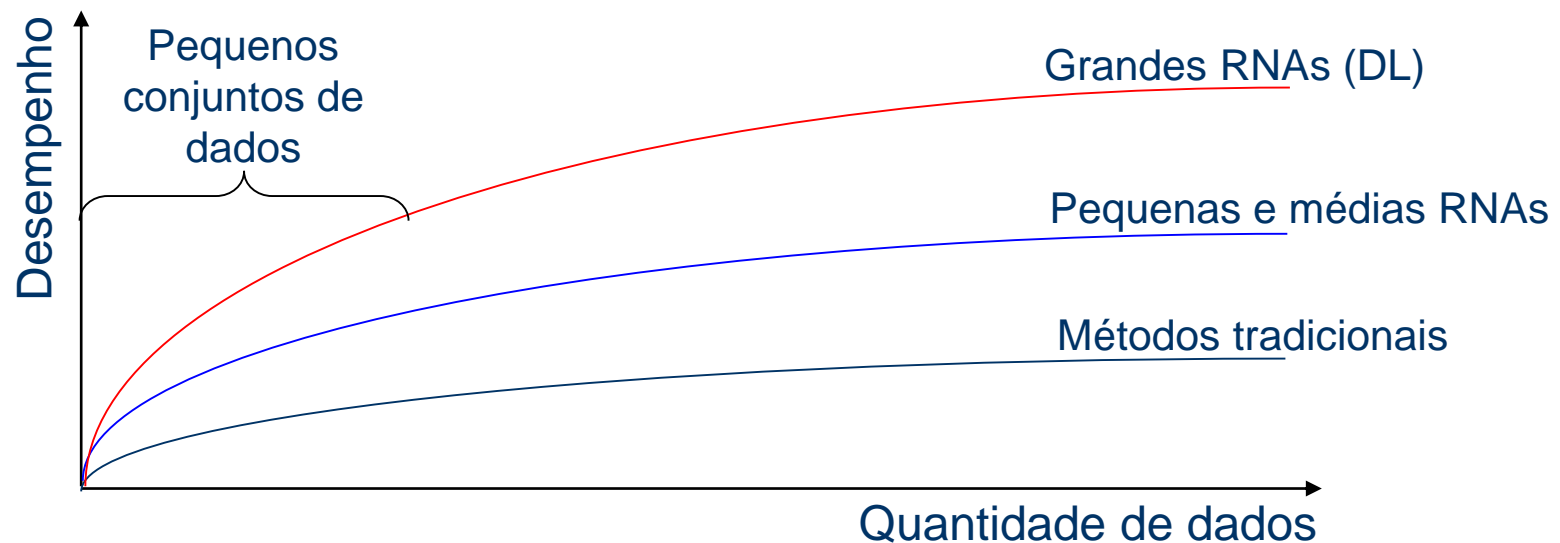
Rede
convolucional



Rede
recorrente

Redes neurais (RN) e deep-learning (DL)

- DL está se difundindo rapidamente em razão de:
 - grande quantidade de dados disponíveis (digitalização da sociedade)
 - computadores cada vez mais rápidos e com mais memória
 - avanço nos algoritmos de treinamento das redes neurais



Objetivo do curso

- Apresentar as áreas da IA de aprendizado de máquinas (ML) e redes neurais (RNA)
- Curso baseado em atividades práticas onde os métodos estudados são utilizados para solução de problemas práticos

Histórico da IA – visão geral

- Antes de 1950 - Métodos estatísticos são criados e refinados
- Década de 1950 – Desenvolvimento de pesquisa pioneira em IA é realizada usando algoritmos simples
- Década de 1960 – Métodos Bayesianos são introduzidos em IA para inferência probabilística
- Década de 1970 – “Inverno” da IA causado pelo pessimismo sobre a eficiência dos métodos
- Década de 1980 – Redescoberta do algoritmo de retro propagação causa o ressurgimento da IA e ressurgimento do interesse nas RNAs

Histórico da IA – visão geral

- Década de 1990 – Pesquisa de IA muda de uma abordagem de métodos baseados em conhecimento (IA clássica) passando para métodos baseados em dados (início de ML)
 - Pesquisadores começam a criar programas para analisar grandes quantidades de dados e tirar conclusões, ou "aprender", a partir dos dados
 - Máquinas de vetores de suporte (SVM), algoritmos de boost e redes neurais (RNA) se tornam populares
 - Tem início a área de computação em paralelo usando redes neurais

Histórico da IA – visão geral

- Década de 2000 – Métodos de agrupamento e de aprendizado não supervisionado se tornam comuns e disseminam
- Década de 2010 – Redes neurais deep learning se tornam possíveis fazendo com que RNAs sejam parte integrante de muitas aplicações e serviços.

Histórico da IA – eventos marcantes

- 1943 – Primeiras redes neurais (McCulloch e Pitts) \Rightarrow muitos dos princípios e ideias da época ainda estão presentes nas RNA atuais
- 1949 – Hebb desenvolveu a primeira regra de aprendizado usando um conceito simples \Rightarrow se dois neurônios conectados estão ativos no mesmo instante de tempo então a conexão entre eles deve ser aumentada
- 1950 – Alan Turing propõe um algoritmo capaz de aprender e se tornar “artificialmente” inteligente
- 1958 – Criação do Perceptron (base das atuais RNAs) por Rosenblatt gerando muita expectativa

Histórico da IA – eventos marcantes

- 1960 – Criação da Adaline (primeira RNA realmente eficiente) por Widrow e Huff
- 1963 – Donald Michie cria um algoritmo usando aprendizado por reforço para jogar ti-tac-toe
- 1967 – Criação da função de ativação sigmóide por Cowan
- 1967 – Criado o algoritmo “Nearest Neighbor” iniciando a área de reconhecimento de padrões
- 1969 - Minsky e Papert apresentam as limitações das redes neurais \Rightarrow pesquisa na área praticamente para por cerca de 15 anos

Histórico da IA – eventos marcantes

- 1972 – Kohonen cria a memória associativa
- 1974 – Werbos cria o algoritmo de retro-propagação
- 1982 – Hopfield cria o modelo conexionista
- 1986 – Reinvenção do algoritmo de retro-propagação por Rumelhart, Hinton e McClelland
- 1988 - Uso de RNA no reconhecimento de caracteres escritos apresenta sucesso
- 1989 – Watkins desenvolve o algoritmo Q-learning, representando um grande avanço na área de aprendizado por reforço

Histórico da IA – eventos marcantes

- 1992 –Tesauro desenvolve o algoritmo TDGammon usando RNA para jogar Gamão, capaz de vencer jogadores campeões, mas não é consistente
- 1995 –Tin Kam Ho inventa o algoritmo “Random Forest” de ML
- 1995 – Cortes e Vapnik criam o algoritmo SVM de ML
- 1997 – IBM Deep Blue vence o campeão mundial de xadrez Kasparov
- 1997 – Hochreiter e Schmidhuber inventam a rede LSTM (long-short-term-memory), representando um grande nas redes recorrentes

Histórico da IA – eventos marcantes

- 1998 – Um time liderado por LeCun cria a base de dados MNIST de dígitos numéricos escritos a mão, que se torna um grande benchmark da área de IA
- 2002 – Criada a Torch Machine Learning, primeira biblioteca de funções para ML
- 2009 – Netflix realiza competição de ML para criar sistema de recomendação
- 2009 – Banco de imagens ImageNet é criado segundo concepção de Fei-Fei Li \Rightarrow gerando o “boom” de IA com RNA-DL

Histórico da IA – eventos marcantes

- 2010 – Criado o site Kaggle que serve como plataforma de competições e banco de dados
- 2011 – Usando ML, sistema Watson da IBM é campeão em competição do jogo Jeopardy
- 2012 – RNAs DL ultrapassam outros métodos de ML
- 2012 – Time do Google Brain, liderado por Andrew Ng e Jeff Dean, cria RNA que reconhece gatos em imagens da internet
- 2014 – Pesquisadores do Facebook criam DeepFace (algoritmo usando DL) capaz de identificar faces com exatidão de 97,35%

Histórico da IA – eventos marcantes

- 2016 – RNAs DL ultrapassam seres humanos em diversas aplicações
- 2016 – Algoritmo AlphaGo do Google vence um jogador profissional de Go
- 2017 – Versão do AlphaGo é generalizada para diversos jogos

Formas de aprendizado

- Existem 3 formas de aprendizado de máquinas:
 - Aprendizado supervisionado
 - Aprendizado não supervisionado
 - Aprendizado por reforço

Formas de aprendizado

- Aprendizado supervisionado:
 - Aprendizado por meio de dados
 - Aprendizado é realizado apresentando conjunto de dados (entradas – saídas)
 - Exige conjunto de dados rotulados e classificados
 - Tarefa de classificação de dados é feita por seres humanos \Rightarrow trabalho exaustivo e demorado
 - Durante aprendizado saída gerada é comparada com saída desejada \Rightarrow diferença entre saída desejada e calculada é usada para treinamento
 - Métodos relacionados \Rightarrow regressão, redes neurais

Formas de aprendizado

- Aprendizado não supervisionado:
 - Aprendizado por meio de dados
 - Saídas desejadas não são fornecidas
 - Não exige classificação de dados por seres humanos \Rightarrow mais fácil obter dados para treinamento
 - Métodos relacionados \Rightarrow agrupamento, pca
 - Somente é capaz de agrupar dados semelhantes

Formas de aprendizado

- Aprendizado por reforço:
 - Aprendizado por meio da interação do “agente” com o ambiente
 - Não exige dados de treinamento \Rightarrow o próprio sistema coleta os dados interagindo com o ambiente
 - Fornecido ao sistema uma forma de verificar se saída gerada é correta ou errada
 - Após término da tarefa sistema recebe uma “nota” do seu desempenho, que é usada para o treinamento
 - Outra área de ML
 - Muito utilizado para gerar “inteligência” para jogos de vídeo game e veículos autônomos


Aprendizado por meio de dados

- Para desenvolver um sistema de ML é necessário:
 - Dados de entrada
 - Dados de saída desejada
 - Forma de medir a eficiência do método
- ML consiste na transformação dos dados de entrada nos dados de saída
- Processo de transformação é aprendido expondo o sistema ao conjunto de dados
- Problema central de ML \Rightarrow aprender como os dados de saída são representados pelos dados de entrada por meio de um processo automático de aprendizado

Aprendizado por meio de dados

Exemplo: Classificação binária


- Desenvolver algoritmo que recebe coordenadas x e y de um ponto e classifica-o como bola branca ou preta
- Entradas \Rightarrow coordenadas dos pontos
- Saída esperada \Rightarrow cores dos pontos
- Medida da eficiência \Rightarrow porcentagem de pontos classificados corretamente



Aprendizado por meio de dados

Exemplo: Classificação binária


- Uma forma de resolver esse problema é fazer uma transformação de coordenadas
- Nesse caso basta calcular a nova coordenada x' do ponto para classificá-lo
- ML realiza esse processo iterativamente verificando o erro de classificação até achar o menor erro possível



Aprendizado por meio de dados

Exemplo: Regressão


- Deseja-se obter uma função que dado o tamanho de uma casa calcula o seu preço
- Entradas \Rightarrow tamanhos das casas
- Saída esperada \Rightarrow preços das casas
- Medida da eficiência \Rightarrow erro médio das estimativas dos preços das casas



Aprendizado por meio de dados

Exemplo: Regressão

- Mesmo processo utilizado na classificação \Rightarrow adota-se uma função e iterativamente faz-se um ajuste até minimizar o erro
- Regressão com um único dado de entrada é fácil
- Como fazer se outras características da casa afetarem o seu preço (localização, número de quartos, idade etc)?



Aprendizado por meio de dados

- Além de classificação binária e regressão uma RNA ou um sistema ML pode realizar inúmeras outras tarefas:
 - Classificação
 - Detecção de objetos
 - Reconhecimento de objetos, como por exemplo faces;
 - Transferência de estilo
 - Geração de novas imagens, músicas, textos etc
 - “Chatbots” (atendente virtual) \Rightarrow BIA, VIVI, ALEXA
 - Previsão de tempo, mercado financeiro etc
 - Controle de robôs
 - Tradução de texto
 - Etc

Aplicações de ML e RNA

- Ciência
- Robótica
- Veículos autônomos
- Medicina
- Processos de manufatura
- Marketing e vendas
- Bancos e finanças
- Seguro
- Segurança
- Muitos outros

Exemplos de aplicações de RNA

- Diversos exemplos
- Remoção de objetos
- Visão noturna
- Restauração de imagem
- Geração de rosto em 3D
- IA percebe pessoas através das paredes
- Veículos autônomos
- Geração de imagens
- Geração de música
- Lógica
- Aprender a andar

Disciplinas do curso

- **Negócios com IA.** Discutir como sistemas de IA podem ser utilizados em ambientes corporativos. O que pode ser obtido com a IA relativo a novos negócios. Vantagens e desvantagens de usar IA. Implicações do uso de inteligência artificial. Custo de desenvolvimento. Apresentação de casos.
- **Análise estatística de dados.** Apresentar a base de matemática, probabilidade e estatística relacionada à análise de dados para IA.
- **Programação em Python para IA.** Apresentar conceitos básicos e avançados de Ciência da Computação usando a linguagem de programação Python. Desenvolver raciocínio para formulação e resolução de problemas computacionais.

Disciplinas do curso

- **Aprendizado de máquinas I.** Apresentar uma visão geral da área de ML, incluindo conceitos e métodos fundamentais utilizados. Métodos de regressão e classificação, métodos de agrupamento, PCA.
- **Aprendizado de máquinas II.** Continuação da disciplina ML I, apresentando métodos mais avançados: árvores de decisão, “random forest”, mapas auto-organizáveis.
- **Introdução a RNAs.** Apresentar os conceitos básicos de redes neurais artificiais: principais arquiteturas, métodos de treinamento, algoritmo de retro-propagação, exemplos de aplicações.
- **RNA DL e plataformas de desenvolvimento I.** Apresentar como RNA DL funciona, os fundamentos de DL e o uso da biblioteca Keras. Como criar, treinar e utilizar uma RNA DL.

Disciplinas do curso

- **RNA DL e plataformas de desenvolvimento II.** Aprofundamento dos conceitos da disciplina RNA DL e plataformas de desenvolvimento I usando a biblioteca TensorFlow. Técnicas avançadas de otimização e ajuste de RNAs.
- **RNAs convolucionais e visão computacional.** Apresentar as RNAs convolucionais, incluindo tipos, configuração treinamento. Aplicação de RNAs convolucionais em processamento de imagens e vídeos para realizar tarefas de detecção e reconhecimento visual, classificação de imagens, reconhecimento de faces etc.
- **RNAs recorrentes e processamento de linguagem natural.** Apresentar as RNAs recorrentes usadas para processamento de sequências temporais, processamento de linguagem natural, música e áudio. Tipos de RNAs recorrentes: GRU e LSTM.

Disciplinas do curso

- **Aprendizado por reforço.** Apresentar o conceito do aprendizado por reforço, uso de recompensas como método de treinamento, as três formas básicas de aprendizado por reforço e suas aplicações usando RNAs.
- **Tópicos avançados em DL.** Apresentar como aplicar e combinar redes neurais para realizar tarefas de criação, tal como, obra de arte, texto, música. Programação em CUDA para programas de execução em paralelo.

Metodologia de ensino

- Curso prático com ênfase na aplicação sem negligenciar a teoria
- Todas disciplinas são baseadas em estudos de casos reais e atividades práticas
- Atividades práticas são realizadas durante as aulas utilizando linguagem de programação Python e softwares amplamente utilizados na área (Keras, TensorFlow, SciKit etc)
- Objetivo é apresentar de forma prática as técnicas utilizadas na área e capacitar os alunos a utilizar essas técnicas em suas próprias aplicações

Professores do curso

- **Coordenação:** Prof. Larissa Driemeier (driemeie@usp.br)
- **Corpo docente:**
 - Prof. Larissa Driemeier (USP)
 - Prof. Eduardo L. L. Cabral (IPEN)
 - Prof. Thiago de C. Martins (USP)
 - Prof. Geisa M. Faustino (Microsoft)
 - Prof. João Paulo P. N. Oliveira (NVIDIA)
 - Prof. Patrícia C. P. Pampanelli (ZAP)
 - Prof. Wagner Luiz Zucchi (USP)
 - Prof. Jun Okamoto Jr. (USP)
 - Prof. Glauber de Bona (USP)

Programação do curso

- Programação das disciplinas
- Monografia:
 - Desenvolvimento de monografia na área de IA
 - Realizada após as disciplinas
 - Trabalho orientado por um professor
 - Equivale a 60 horas