



Universidade de São Paulo  
IAD-006 - Aprendizado de Máquina 2

## **Exercício 2**

Self Organizing Maps

Bruno Rodrigues Silva RA:74313

São Paulo - Setembro de 2020

## Objetivos

- Explicação do algoritmo Self Organizing Maps;
- Realização de atividade prática de aplicação do método SOFM disponível em [Source Code](#);
- Explicação do caso de estudo da atividade prática.

# Self Organizing Maps

## 1. Sobre o algoritmo

O algoritmo Self Organizing Maps (SOM) é um tipo de rede neural que é treinado utilizando aprendizado não supervisionado, foi idealizada por Kohonen no artigo Self-organized formation of topologically correct feature maps em 1982 [1], este algoritmo surge como uma solução para problemas de altas dimensionalidade uma vez que devido ao aspecto construtivo do seu algoritmo de aprendizado, é performedo um mapeamento entre os inputs e outputs do modelo, dessa maneira é possível definir a quantidade de clusters gerados por esse mapeamento em altas dimensões e trazer essa relação para dimensões menores e de maior significância relativa ao problema em foco.

O modelo em si tem uma estrutura diferente de outras redes neurais [2] visto que é composto de uma grade 2D de neurônios que são distribuídos linearmente no espaço da grade - numa estrutura que se assemelha a uma camada de íons numa ligação metálica pura e eletricamente igualmente distribuída, onde os cátions são representados pelos neurônios e os ânions são representados pelo espaço vazio entre neurônios que será preenchido com inputs de features nessa camada.

Esta estrutura tem como algoritmo de aprendizado o foco em encontrar a melhor unidade ligante ou BMU (Best Matching Unit) [3] de acordo com alguma métrica de similaridade desejada pelo usuário - tal como o erro quadrático médio - e distorcer k neurônios da rede num passo proporcional a  $L \cdot F$ , onde L é a taxa de aprendizagem e F é a força relativa entre o neurônio e o BMU. Vale também abordar que L normalmente não é constante ao longo do treinamento da rede, decaindo de acordo com a relação  $L(t) = L_0 \exp(-\frac{t}{\lambda})$ , onde lambda é um hiperparâmetro do modelo.

## 2. Atividade prática de aplicação de SOM

Esse projeto recebeu diversas iterações e mudanças por minha causa, por isso acredito que não pude abordar o tema na profundidade que eu tenho interesse. inicialmente a proposta deste trabalho era a utilização de SOM para melhorar o desempenho de treinamento de redes neurais convolucionais através de compressões em imagens para diversas atividades (classificação, detecção, etc.), porém por conta de falta de poder de processamento versus tempo hábil, tive que partir para um plano B, ainda utilizando imagens. Portanto propus a utilização de SOM para compressão de imagens em tons de cinza de fotos do meu gato e avaliar como a rede generaliza para diversas fotos do mesmo gato.

### 2.1. O conjunto de dados

O conjunto de dados é composto por 4 imagens do meu gato, a rede será treinada em uma das imagens e tentará comprimir as outras 3 imagens como teste.

### 2.2. Treinamento do modelo

Para o treinamento do modelo foi utilizada a biblioteca pyERA [4] que tem como foco tratamento de imagens por meio de SOMs com diferentes arquiteturas, a arquitetura escolhida foi de uma SOM contendo 128 neurônios treinada por 50 épocas, utilizando batch size de 64 ítems, numa imagem de tamanho 172x172x1 (tons de cinza) utilizando o algoritmo de decaimento exponencial mencionado na introdução do projeto.

### 2.3. Resultados

A rede teve dificuldade em identificar claramente o objeto procurado nas iterações iniciais, mas melhorou depois de poucas iterações conforme mostrado nas figuras 1, 2 e 3.

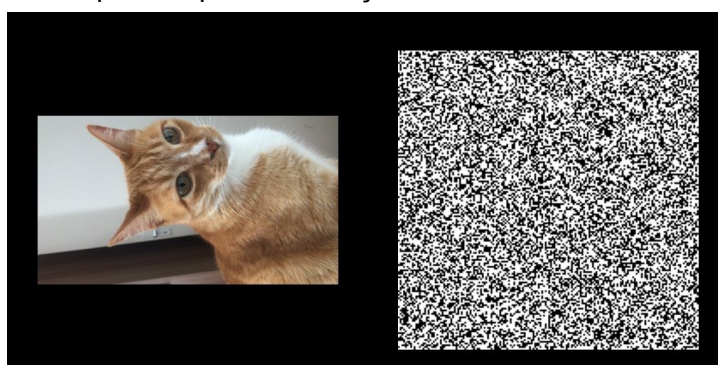


Figura 1: resultado de 1 iteração



Figura 2: resultado de 10 iterações



Figura 3: resultado de 26 iterações

[Link](#) para o Gif com todas as iterações

### 3. Discussão sobre os resultados

A aplicação de SOM para a compressão de imagens se mostrou pouco eficiente, esse fato decorreu, provavelmente pela falta de épocas de treinamento e de uma maior rede de neurônios, uma vez que visualmente é possível encontrar alguma relação entre a imagem real e a imagem formada pela rede SOM, mas por conta do desvio de caminho tomado inicialmente não foi possível aprofundamento dos resultados.

Apesar da rede ser treinada apenas em um exemplo de imagem de gato, visualmente existe uma detecção de arestas nas imagens, o que mostra a capacidade do modelo em identificar diferenças grandes entre camadas de pixels, o que pode mostrar uma capacidade desse modelo em realizar segmentação de cenas em imagens com diversos planos.

Para próximos estudos é interessante responder à pergunta sobre como a utilização de SOMs para compressão de imagens afeta as métricas de redes neurais convolucionais, como tempo de treinamento, acurácia e outras métricas de validação de modelo de acordo com o problema em questão.

## 4. Referências

- [1] Kohonen, T. Self-organized formation of topologically correct feature maps. *Biol. Cybern.* 43, 59–69 (1982). <https://doi.org/10.1007/BF00337288>
- [2] Resumo de características e arquitetura  
<https://towardsdatascience.com/kohonen-self-organizing-maps-a29040d688da>
- [3] Algoritmo de aprendizado de SOMs, [https://www.saedsayad.com/clustering\\_som.htm](https://www.saedsayad.com/clustering_som.htm)
- [4] Biblioteca pyERA, <https://github.com/mpatacchiola/pyERA/>